포트폴리오

AI ｜LLM Engineer — 송한솔 포트폴리오

송한솔 (Song Hansol)

국민대학교 일반대학원 데이터사이언스학과 석사졸

건국대학교 글로컬캠퍼스 경영경제학부 경제학전공 학사졸

📌 한 줄 소개

> 자연어처리 기반 AI 기술을 바탕으로 시스템 고도화 경험을 갖춘 AI 엔지니어입니다.

Contact

- **이름:** 송한솔

ssolllll - Overview

ssolllll has 5 repositories available. Follow their code on GitHub.

https://github.com/ssolllll

Aa 학교	설명
💻 Programming Languages	Python, Spring Boot, Vue 2
💻 LLM Framework	OpenAI API, Prompt Engineering, LangChain, LangGraph, RAG, PEFT, MCP, Transformer, llm-as-a-judge, vLLM, ollama
💻 Machine Learning	Tensorflow, Pytorch, scikit-learn
💻 Data Analysis	Pandas, Matplotlib, Seaborn, plotly
💻 DataBase	Oracle, MySQL, FAISS, Milvus

Aa 학교	설명
💻 Software Engineering	Git, Linux, Docker, Ubuntu

💼 주요 경력 요약

회사	부서	직급	재직 기간
(주)이트너스	기업부설연구소	Pro (CL1)	2024.06 ~ 재직중
(주)씨티아이랩	AI R&D Lab	주임 연구원	2023.08 ~ 2024.06
(주)포스켄	AI응용서비스개발	연구원	2020.09 ~ 2020.12 (계약직)

🎓 교육 이수

- 핀테크 특화 AI 엔지니어 부트캠프 (2022.11 ~ 2023.04) / 서울산업진흥원, 에이블스쿨 / 데이터 분석, 머신러닝, 딥러닝
- 빅데이터 소셜마케팅 전문인력 양성과정(2019.06 ~ 2019.08) / 한경아카데미, 청년취업아카데미, 450시간

Publications

- “언론 보도의 감정이 IPO 초기수익률에 미치는 영향에 대한 실증연구” 학위논문. (2022)

Conferences

- “뉴스 기사의 감정이 IPO 초기수익률에 미치는 영향에 대한 실증연구.” KMIS International Conference (2022). (발표자)

자격증

SQL개발자(SQLD 자격) - 한국데이터베이스진흥센터

(주) 이트너스 – AI PL팀 / 사원

근무 지역: 경기도 과천

👩‍💻 경력기술서

```
1. AI Chatbot 구축 프로젝트 (2025.01 ~ 2025.06)

역할: 설계, 개발, 운영 전반 단독 수행
기술스택: OpenAI API, LangChain, LangGraph, MLFlow, Milvus, vLLM, gemma3

- 사내 챗봇 레거시가 없는 상태에서 기획부터 아키텍처 설계, 백엔드 개발, 운영 배포까지 전 과정 단독 주도
- 3월 초 오픈 일정에 맞춰 초기에는 LangChain v0.1 기반 단일 턴 QnA 시스템으로 MVP
```

개발
- 이후 단계적으로 LangChain v0.2 업그레이드, LangGraph 도입을 통해 멀티턴 대화 흐름 구성 및 프롬프트 체인 설계
- 사내 문서 DB 기반 RAG 구조, 이전 질문 맥락을 고려한 응답 시스템 구현
- MLFlow 기반 응답 모니터링 체계 구축, llm-as-a-judge 적용으로 정량화된 응답 품질 평가 시스템 운영
- OpenAI API 자체 모델 전환을 위해 vLLM 기반 gemma3 모델 테스트 완료, 쿠버네티스 기반 GPU 인프라 전환 및 모델 내재화 예정

성과:
전사 사내 QnA 챗봇 시스템을 설계 및 개발 운영 배포 완료
LLM 도입 및 내재화, 프롬프트 체계, LangGraph 등 최신 기술을 현업에 안정적으로 적용

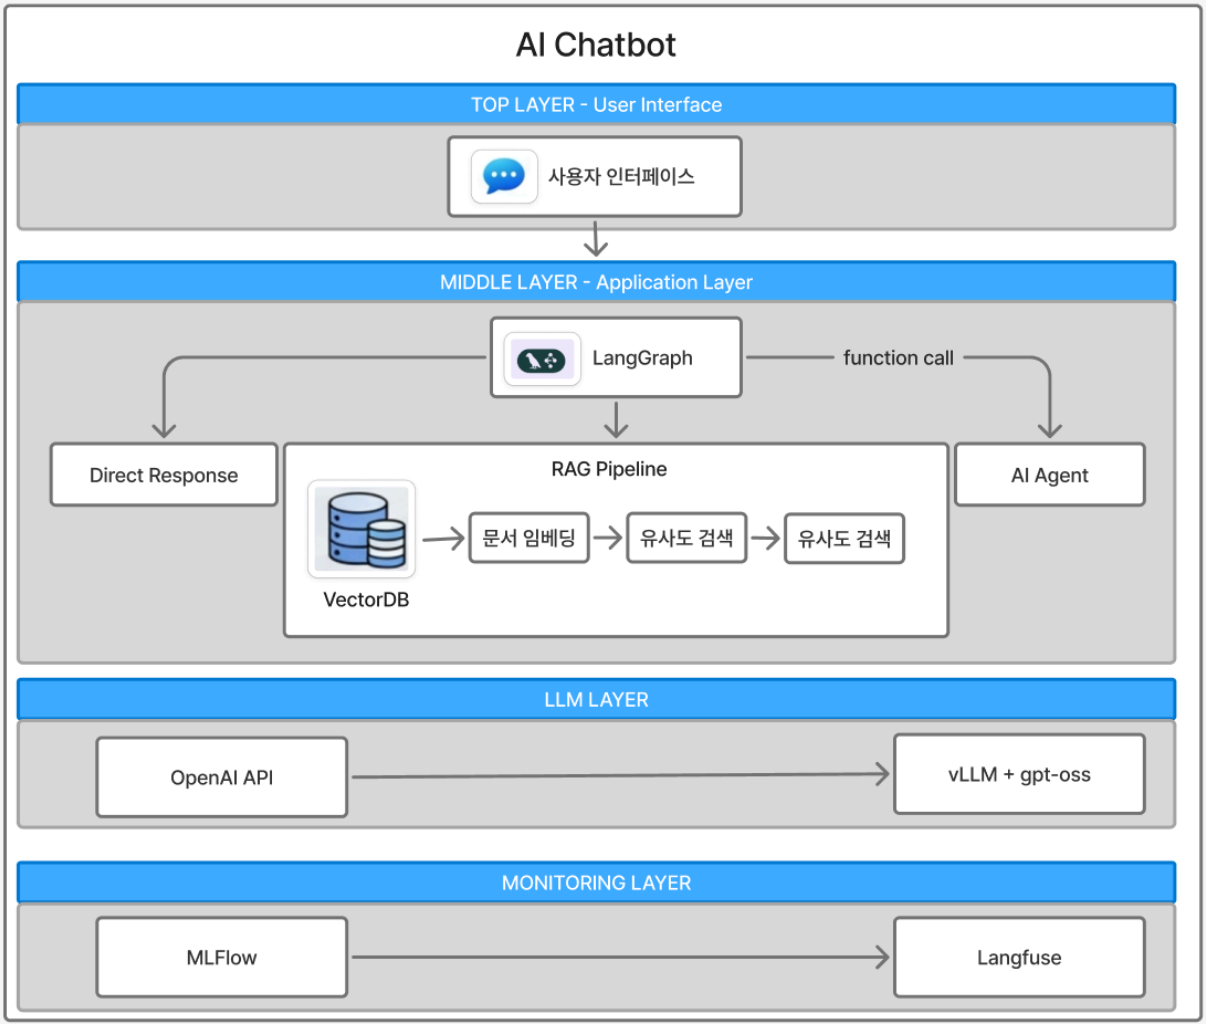

2. AICC (AI Contact Center) 구축 프로젝트 (2025.05)

역할: 시스템 설계, STT-TTS 파이프라인 개발, NLP 모델 개선
기술스택: Whisper, FAISS, FastAPI, KV Caching, TTS, VectorDB

- 기존 AICC 응답률(21.4%)의 한계를 극복하기 위해 Whisper 기반 STT로 교체 및 질의응

답 구조 재설계
- VectorDB(FAISS) 기반의 RAG 구조 적용으로 질문-응답 정확도를 극대화
- KV Caching 구조를 도입하여 STT Vector 검색 TTS로 이어지는 음성 파이프라인 구축
- OpenAI 기반 구조 전환 후 응답 성공률 97.3% 달성, 사용자 만족도 및 정확도 큰 폭 개선
- 기존 음성 응답 서비스의 실시간성 문제 해결 및 AICC 서비스 6개 지역으로 확장 지원

성과:
응답 성공률 21.4% 97.3%(답변 정확도)로 비약적 개선
음성 기반 AI 응답 시스템의 성능 및 실시간성 확보
회사 전체 AICC 모델 교체 적용

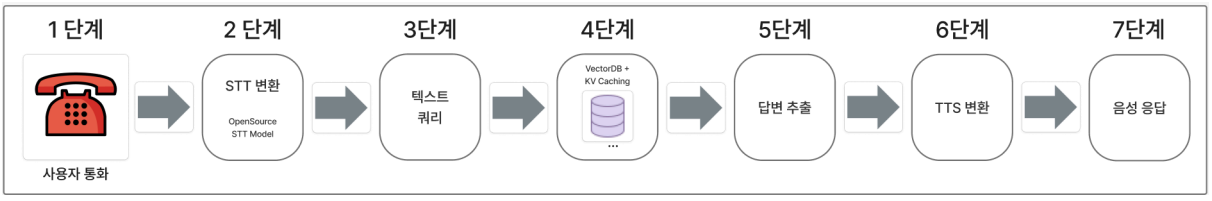

3. 채팅 시스템 1차 개발 (2024.10 ~ 2024.11)

역할: 백엔드 설계 및 구현
기술스택: Spring Boot, MySQL, REST API

- Spring Boot 기반 사내 채팅 시스템의 핵심 기능 백엔드 구현
- 채팅방 목록 조회, 상세 메시지 조회, 첨부파일 업로드/다운로드 처리 등 기능 개발
- 비즈니스 초기 기획 단계부터 참여하여 채팅 기능의 구조 설계와 로직 검토에 기여
- 약 2개월간 집중 개발하여 채팅시스템 기초를 확립 후 회사 AI 기술 도입을 위해 다른 프로젝트 투입

성과:
독립 모듈 형태로 백엔드 구현 완료, 이후 서비스 전반에 재활용 가능한 구조 설계
실사용 기반의 커뮤니케이션 도구 초기 구조 기획 및 구현 주도

4. 학자금 지원 어시스턴트 개발 프로젝트

기술 스택 : GPT-VISION, OCR, FastAPI, Redis

- LLM과 OCR API를 기반으로, 학자금 이미지(첨부파일) 내 텍스트를 자동 인식하고 정책과 비교하여 예상 지원금 산출
- 초기에는 GPT-4-Vision 기반 멀티모달 모델로 이미지 인식 및 정책 매칭을 수행했으나, 응답 지연 및 비용 문제로 경량화된 OCR+LLM 조합으로 전환
- 문서 내 텍스트의 좌표와 내용 인식 정책 기준과 비교 예상 지원금 산출까지의 전 과정을 자동화
- 담당자가 수작업으로 처리하던 업무를 자동화된 어시스턴트 형태로 대체함으로써 실무 효율성을 향상

- 해외 대학 등 비표준 양식의 이미지에 대해서는 OCR 텍스트 추출 후 번역 이미지에 오버레이하여 가독성 높인 형태로 시각화 구현
- Redis Stream & FastAPI 연동을 통한 빠른 API 처리 구현

성과 요약:
멀티모달 기반 복잡 문서 해석을 자동화하는 AI 어시스턴트의 설계 및 구현
실제 학자금 담당자의 실무를 보조하는 방식으로, 업무 정확도 및 처리 속도 개선에 기여

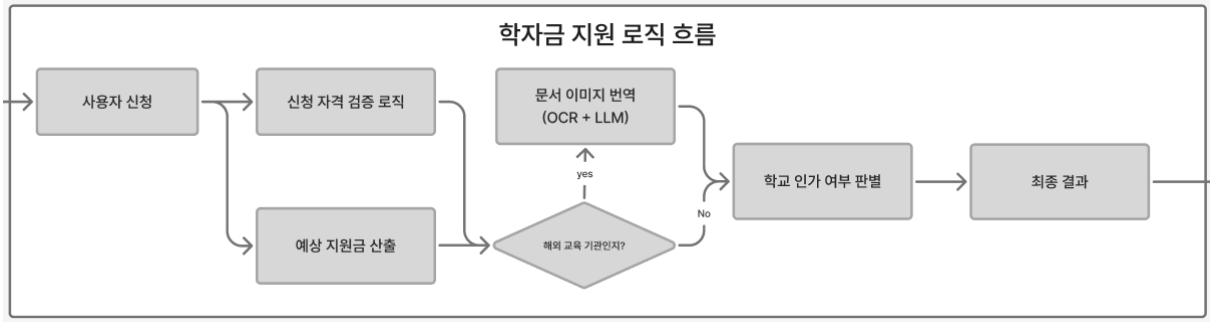

5. 연말정산 AI 도우미 챗봇 구축 (2025.12 ~ 2026.01)
역할: 아키텍처 설계, 부하 테스트 및 최적화, LLM 서빙

기술스택: Kubernetes(K8s), Milvus, vLLM, GPT-OSS, LangChain, JMeter, Docker, FastAPI

대규모 트래픽 대응을 위한 시스템 설계 및 검증
연말정산 집중 기간의 고부하 상황을 대비하여 JMeter를 활용한 부하 테스트 실시 (동시 접속자 1,000명 기준 성능 검증 완료)
쿠버네티스(Kubernetes) 기반의 오토스케일링 환경을 활용하여 트래픽 변화에 유연하게 대응할 수 있는 인프라 구조 설계
기존 FAISS 대비 대용량 벡터 데이터 관리에 최적화된 Milvus를 메인 Vector DB로 채택하여 검색 확장성 확보
보안 및 비용 최적화를 위한 LLM 내재화
민감한 개인정보 보호를 위해 외부 API 호출 대신 내부 오픈소스 모델인 GPT-OSS를 vLLM으로 서빙하여 On-premise 환경 구축
복잡한 연말정산 세법 문서를 RAG 구조로 색인화하여 전문적인 질의응답이 가능하도록 구현
실무 중심의 고도화 작업

기존 사내 QnA 챗봇의 범용 엔진을 연말정산 특화 도메인으로 분리·확장한 발전형 모델 구현
사용자 질문 패턴 분석을 통해 자주 묻는 질문(FAQ)에 대한 응답 정확도 및 처리 속도 최적화

성과:

안정적 서비스 운영: 동시 접속 1,000명 환경에서도 지연 없는 응답 성능 확보 및 인프라 안정성 증명
보안성 강화: 내부 모델 활용을 통해 데이터 외부 유출 우려를 원천 차단한 기업용 AI 서비

```
스 모델 제시
운영 효율화: 매년 반복되는 연말정산 문의 업무의 자동화로 인사·총무 담당자의 업무 부하 대폭 경감
```

- AI Chatbot 동일한 구조를 가짐

(주) 씨티아이랩 – AI R&D팀 / 주임

재직 기간: 2023.08 ~ 2024.06

근무 지역 : 서울

👩‍💻 경력 기술서

```
개발 환경 : Linux, Docker, Ubuntu, MS Azure
Toolkit : Airflow, Clickhouse DB

1. NLP 연구

(1) LLM 기반 자동 분류 시스템
① HTTP 패킷 데이터 분석을 통한 사이버 공격 오토 프로파일링 개발.
- custom layer을 통한 모델 파인 튜닝 진행.
- 도메인에 맞는 tokenizer 학습.
- Pytorch & Huggingface 패키지로 구현.
-
② PEFT을 통한 추론 속도 개선
- Huggingface 패키지로 구현.
- ①번 Task를 PEFT를 통한 속도 개선.

(2) LLM 기반 Anomaly Detection
- 패킷 분석을 통한 사이버 공격 탐지.
- Pytorch & Huggingface 패키지 사용.
- Task : MLM을 통한 데이터 학습
- 기본 토크나이저 사용.
- 논문 구현을 통한 모델 설계.

(3) LLM을 활용한 XAI 구현.
- Prompt Engineering을 통한 기능 구현.
- 폐쇄망에서 활용할 XAI용 VectorDB 구성(연구진행)

2. 프로젝트 및 POC
참여 프로젝트 및 POC
① 신한은행 프로젝트 TF(24.01.02 ~ 24.01.31)
성과 : 기존 9~50% 탐지율 -> 80% 이상 탐지 달성

- encoder-decoder 모델을 통한 data imbalance 해결.
- 데이터 분석을 통한 문제점 발견 및 해결방안 마련

② 국회 도서관 POC(24.02.19 ~ 24.03.20)
```

```
- 사이트에 맞는 모델 커스텀 고도화
- ETL 자동화 스크립트 담당
- 패킷 데이터 분석을 통한 모델 고도화
- 패킷 분석

성과 : 기존 보안 장비를 통과한 위협 패킷 데이터 다수 탐지.

③ 국가보안기술연구소 (23.12.15 ~ 24.05.22)
- 패킷 분석 어시스턴트 LLM 개발
- 패킷 데이터 분석을 통한 모델 고도화
- ETL 자동화 스크립트 담당
- 학습 데이터 자동화를 통한 모델 파인 튜닝
- 의존성 문제 해결을 위한 제품 코드 리뉴얼
- 패킷 분석
```

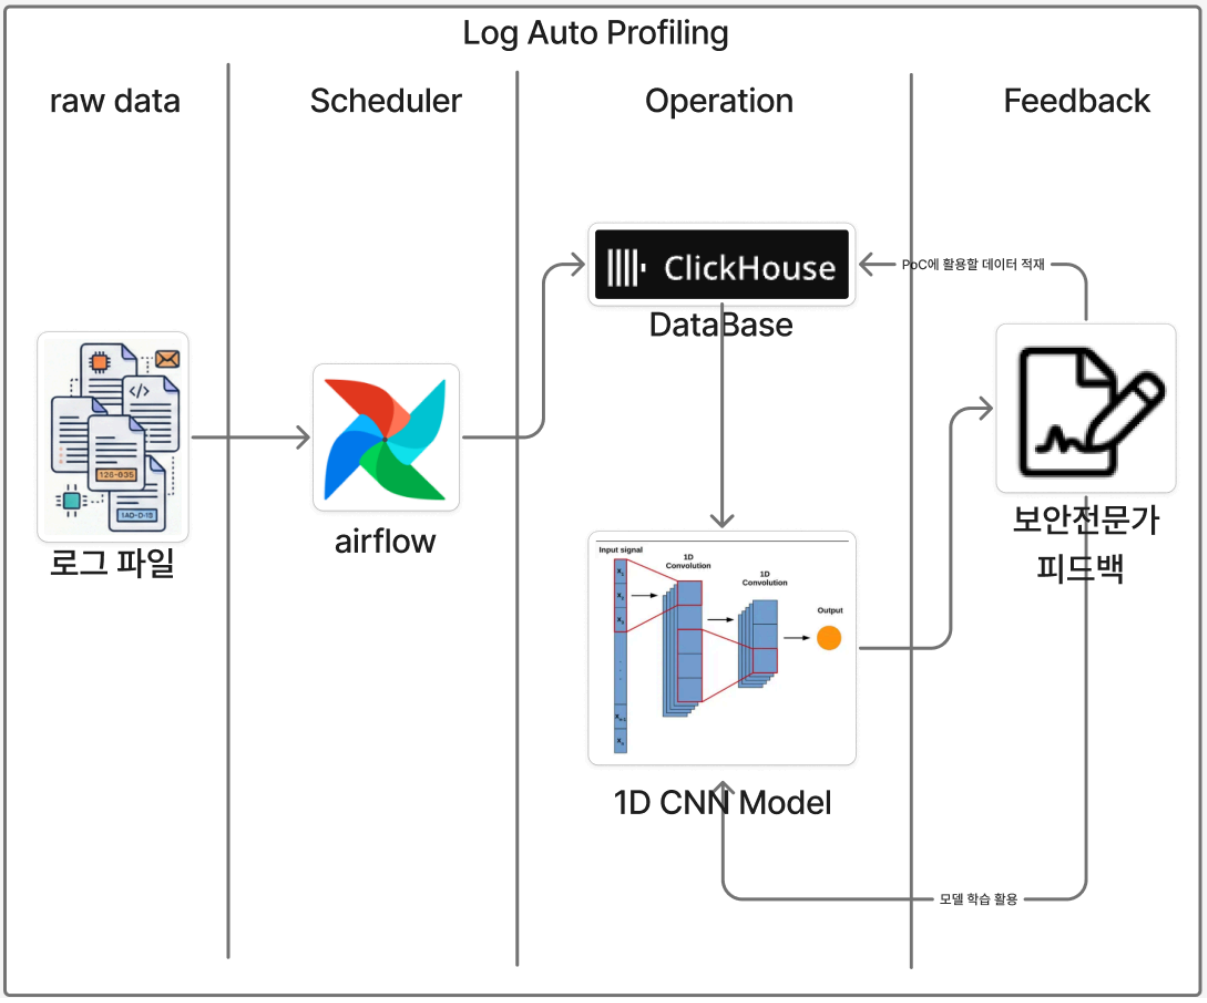

(주) 포스켄 – AI응용서비스개발 / 연구원 (계약직)

재직 기간: 2020.09 ~ 2020.12

근무 지역 : 서울

👩‍💻 경력기술서

```
1. 도면 파일럿 프로젝트
    - 2021-01-01 ~ 2021-01-01
    - 도면 이미지를 딥러닝을 통하여 객체를 제대로 인식시키는 프로젝트.
    - 프로젝트에서 벽의 모서리 탐지 감지를 통해 이미지를 제대로 인식시키는 업무.

1. 패션추천시스템 구축
    - 2020-09-01 ~ 2020-12-01
    - 정부 사업 일환으로 패션추천시스템 구축 진행.
    - 담당 업무 : 패션추천시스템에 활용할 개인 선호도 가중치 계산.
```

자기소개서

성격의 장단점

강점: 유연한 대처 능력과 실행 중심의 사고

저의 가장 큰 강점은 상황에 맞는 유연한 대처 능력입니다.

저는 단순히 환경에 적응하는 것을 넘어, 주어진 조건 안에서 내가 할 수 있는 최선의 해답을 찾는 것을 중요하게 생각합니다.

항상 스스로에게 던지는 질문이 있습니다. “그래서 내가 지금 할 수 있는 게 뭐야?”

이 질문은 막막하거나 불확실한 상황에서도 저를 움직이게 만드는 동력이며, 저의 행동의 출발점이 됩니다.

사내 챗봇 프로젝트 초기, 기술적 레퍼런스나 기존 시스템이 전혀 없는 상태에서 프로젝트 방향조차 정해지지 않았습니다. 이때 저는 LangChain v0.1을 참고하여 MVP를 빠르게 구축했고, 이후 LangGraph 도입 및 Modular RAG 구조 적용으로 점진적인 기술 고도화를 이뤄냈습니다.

이처럼 **불확실한 조건 속에서도 최적의 대안을 찾고 실행으로 옮기는 능력**은 제가 강하게 믿는 저의 장점입니다.

단점: 과도한 수용 성향 → 비판적 사고로 보완 중

저는 모든 의견이나 방향을 수용하려는 경향이 있습니다.

하지만, 최근 웹 개발 프로젝트를 통해 이 단점을 실감하며 개선해 나가고 있습니다.

웹 프로젝트 초기에 설계상의 의문점이 있었지만, 그때 문제 제기를 하지 않고 그대로 진행했습니다.

결국 해당 문제가 프로젝트 막판에 구조 변경으로 이어지는 큰 이슈로 발전했습니다.

이 경험을 계기로 저는 다음과 같은 변화의 노력을 시작했습니다:

- 설계 및 기획 단계에서 비판적인 사고를 갖기
- 기술적 방향성에 대해 더욱 능동적으로 의견 제시하기

자신 있는 프로젝트

프로젝트 개요: 사내 QnA 챗봇 시스템 구축

기업 내 LLM 기반 시스템이 전무한 상태에서,

설계 → 개발 → 운영까지 전 과정을 단독 주도한 프로젝트입니다.

이 경험을 통해 실제 환경에서의 LLM 기반 시스템 구축 역량과 문제 해결 능력을 체득했습니다.

기술 스택 및 아키텍처

- **LLM API & 프레임워크**

  OpenAI GPT, LangChain v0.1 → LangGraph 기반 Agent 구조로 고도화
- **질문 유형 분기 처리**
  - 간단한 질문: RAG 생략, 빠른 응답
  - 복잡한 질문: Modular RAG 기반 정교한 응답
  - 함수 호출형 요청: LangGraph `func_call`을 통한 Agent 설계(개인 공부 중인 MCP를 통해 func_call 대체 예정)
- **품질 관리 및 평가**
  - MLflow: 응답 품질 실시간 모니터링
  - llm-as-a-judge: 정확도, 명확성, 깊이, 관련성, 유용성 5가지 기준의 정량 평가 (5점 척도)

고도화 및 확장 전략

- **LLM 내재화 예정**
  - OpenAI → Gemma 3 기반 모델 재설계
  - 추론 엔진: vLLM
  - 최적화: 양자화 적용으로 GPU 자원 최소화
- **배포 환경 개선**
  - 추후 모델 내재화를 위해 Kubernetes 기반 배포할 예정
  - 확장성과 안정성 확보를 위한 파이프라인 재구축

핵심 성과 및 성장

- 사내 최초의 LLM 기반 시스템을 제로에서 구축
- Prompt 설계, RAG 파이프라인 구성, Agent 아키텍처 설계 등

  LLM 실전 기술 전반을 경험
- 모델 경량화, 품질 평가 프레임워크, 인프라 설계 등

  운영과 확장성까지 고려한 종합적 문제 해결 역량 확보